

大模型微调部署

QLora微调&GGUF模型转换



课程内容

- 1.LLama Factory自定义多轮对话数据集
- 2.LoRA与QLoRA
- 3.大模型转换为 GGUF 以及使用 ollama 运行

案例：Qwen模型转换为 GGUF 以及使用 ollama 部署

LoRA与QLoRA

LoRA: LoRA 是一种用于微调大型语言模型的技术，通过低秩近似方法降低适应数十亿参数模型（如 GPT-3）到特定任务或领域。

QLoRA: QLoRA 是一种高效的大型语言模型微调方法，它显著降低了内存使用量，同时保持了全 16 位微调的性能。它通过在一个固定的、4 位量化的预训练语言模型中反向传播梯度到低秩适配器来实现这一目标。

什么是 GGUF

GGUF 格式的全名为 (GPT-Generated Unified Format)，提到 GGUF 就不得不提到它的前身 GGML (GPT-Generated Model Language)。GGML 是专门为了机器学习设计的张量库，最早可以追溯到 2022/10。其目的是为了有一个单文件共享的格式，并且易于在不同架构的 GPU 和 CPU 上进行推理。但在后续的开发中，遇到了灵活性不足、相容性及难以维护的问题。

为什么要转换 GGUF 格式


在传统的 Deep Learning Model 开发中大多使用 PyTorch 来进行开发，但因为在部署时会面临相依 Library 太多、版本管理的问题才有了 GGML、GGMF、GGJT 等格式，而在开源社群不停的迭代后 GGUF 就诞生了。

GGUF 实际上是基于 GGJT 的格式进行优化的，并解决了 GGML 当初面临的问题，包括：

- 1) 可扩展性：轻松为 GGML 架构下的工具添加新功能，或者向 GGUF 模型添加新 Feature，不会破坏与现有模型的兼容性。
- 2) 对 mmap（内存映射）的兼容性：该模型可以使用 mmap 进行加载（原理解析可见参考），实现快速载入和存储。（从 GGJT 开始导入，可参考 GitHub）
- 3) 易于使用：模型可以使用少量代码轻松加载和存储，无需依赖的 Library，同时对于不同编程语言支持程度也高。
- 4) 模型信息完整：加载模型所需的所有信息都包含在模型文件中，不需要额外编写设置文件。
- 5) 有利于模型量化：GGUF 支持模型量化（4 位、8 位、F16），在 GPU 变得越来越昂贵的情况下，节省 vRAM 成本也非常重要。

课后作业

1. 掌握LoRA与QLoRA的区别
2. 掌握GGUF的基本概念与模型转换
3. 掌握LLama Factory量化微调训练
4. 将Qwen模型 转换为 GGUF 以及然后使用ollama调用模型



End



Thanks