

Qwen打包部署（大模型转换为 GGUF 以及使用 ollama 运行）

Qwen打包部署（大模型转换为 GGUF 以及使用 ollama 运行）

1. 将hf模型转换为GGUF
 - 1.1 需要用llama.cpp仓库的convert_hf_to_gguf.py脚本来转换
 - 1.2 执行转换
 - 1.3 转换后的模型
2. 使用ollama运行gguf
 - 2.1 安装ollama
 - 2.2 启动ollama服务
 - 2.3 创建ModelFile
 - 2.4 创建自定义模型
 - 2.5 运行模型：

1. 将hf模型转换为GGUF

1.1 需要用llama.cpp仓库的convert_hf_to_gguf.py脚本来转换

```
git clone https://github.com/ggerganov/llama.cpp.git
pip install -r llama.cpp/requirements.txt
```

1.2 执行转换

```
# 如果不量化，保留模型的效果
python llama.cpp/convert_hf_to_gguf.py ./Meta-Llama-3-8B-Instruct --outtype f16
--verbose --outfile Meta-Llama-3-8B-Instruct-gguf.gguf
# 如果需要量化（加速并有损效果），直接执行下面脚本就可以
python llama.cpp/convert_hf_to_gguf.py ./Meta-Llama-3-8B-Instruct --outtype
q8_0 --verbose --outfile Meta-Llama-3-8B-Instruct-gguf_q8_0.gguf
```

这里--outtype是输出类型，代表含义：

q2_k: 特定张量（Tensor）采用较高的精度设置，而其他的则保持基础级别。

q3_k_l、q3_k_m、q3_k_s: 这些变体在不同张量上使用不同级别的精度，从而达到性能和效率的平衡。

q4_0: 这是最初的量化方案，使用 4 位精度。

q4_1 和 q4_k_m、q4_k_s: 这些提供了不同程度的准确性和推理速度，适合需要平衡资源使用的场景。


q5_0、q5_1、q5_k_m、q5_k_s: 这些版本在保证更高准确度的同时，会使用更多的资源并且推理速度较慢。

q6_k 和 q8_0: 这些提供了最高的精度，但是因为高资源消耗和慢速度，可能不适合所有用户。

fp16 和 f32: 不量化，保留原始精度。

```
问题 输出 调试控制台 终端 端口 ②
• root@autodl-container-37b646b795-ed5ca8a:~/autodl-tmp/llama.cpp# cd ..
• root@autodl-container-37b646b795-ed5ca8a:~/autodl-tmp# python llama.cpp/convert_hf_to_gguf.py /root/autodl-tmp/Llama3-8B/LLM-Research/Meta-Llama-3-8B-Instruct-merged2 --outtype q8_0 --verbose --outfile /root/autodl-tmp/Llama3-8B/LLM-Research/Meta-Llama-3-8B-Instruct-gguf8.gguf
INFO:hf-to-gguf:Loading model: Meta-Llama-3-8B-Instruct-merged2
INFO:gguf:gguf_writer:gguf: This GGUF file is for Little Endian only
INFO:hf-to-gguf:Exporting model...
INFO:hf-to-gguf:gguf: loading model weight map from 'model.safetensors.index.json'
INFO:hf-to-gguf:gguf: loading model part 'model-00001-of-00004.safetensors'
INFO:hf-to-gguf:token_embd.weight, torch.bfloat16 --> Q8_0, shape = {4096, 128256}
INFO:hf-to-gguf:blk.0.attn_norm.weight, torch.bfloat16 --> F32, shape = {4096}
INFO:hf-to-gguf:blk.0.ffn_down.weight, torch.bfloat16 --> Q8_0, shape = {14336, 4096}
INFO:hf-to-gguf:blk.0.ffn_gate.weight, torch.bfloat16 --> Q8_0, shape = {4096, 14336}
INFO:hf-to-gguf:blk.0.ffn_up.weight, torch.bfloat16 --> Q8_0, shape = {4096, 14336}
INFO:hf-to-gguf:blk.0.ffn_norm.weight, torch.bfloat16 --> F32, shape = {4096}
INFO:hf-to-gguf:blk.0.attn_k.weight, torch.bfloat16 --> Q8_0, shape = {4096, 1024}
INFO:hf-to-gguf:blk.0.attn_output.weight, torch.bfloat16 --> Q8_0, shape = {4096, 4096}
INFO:hf-to-gguf:blk.0.attn_q.weight, torch.bfloat16 --> Q8_0, shape = {4096, 4096}
INFO:hf-to-gguf:blk.0.attn_v.weight, torch.bfloat16 --> Q8_0, shape = {4096, 1024}
INFO:hf-to-gguf:blk.1.attn_norm.weight, torch.bfloat16 --> F32, shape = {4096}
INFO:hf-to-gguf:blk.1.ffn_down.weight, torch.bfloat16 --> Q8_0, shape = {14336, 4096}
INFO:hf-to-gguf:blk.1.ffn_gate.weight, torch.bfloat16 --> Q8_0, shape = {4096, 14336}
INFO:hf-to-gguf:blk.1.ffn_norm.weight, torch.bfloat16 --> F32, shape = {4096}
INFO:hf-to-gguf:blk.1.attn_k.weight, torch.bfloat16 --> Q8_0, shape = {4096, 1024}
INFO:hf-to-gguf:blk.1.attn_output.weight, torch.bfloat16 --> Q8_0, shape = {4096, 4096}
INFO:hf-to-gguf:blk.1.attn_q.weight, torch.bfloat16 --> Q8_0, shape = {4096, 4096}
INFO:hf-to-gguf:blk.1.attn_v.weight, torch.bfloat16 --> Q8_0, shape = {4096, 1024}
INFO:hf-to-gguf:blk.2.attn_norm.weight, torch.bfloat16 --> F32, shape = {4096}
INFO:hf-to-gguf:blk.2.ffn_down.weight, torch.bfloat16 --> Q8_0, shape = {14336, 4096}
INFO:hf-to-gguf:blk.2.ffn_gate.weight, torch.bfloat16 --> Q8_0, shape = {4096, 14336}
INFO:hf-to-gguf:blk.2.ffn_up.weight, torch.bfloat16 --> Q8_0, shape = {4096, 14336}
```

1.3 转换后的模型



2. 使用ollama运行gguf

2.1 安装ollama

```
curl -fsSL https://ollama.com/install.sh | sh
```

2.2 启动ollama服务

```
ollama serve
```

2.3 创建ModelFile

复制模型路径，创建名为“ModelFile”的meta文件，内容如下

```
#GGUF文件路径
FROM /root/autodl-tmp/Llama3-8B/LLM-Research/Meta-Llama-3-8B-Instruct-gguf8.gguf
```

2.4 创建自定义模型

使用ollama create命令创建自定义模型

```
ollama create llama-3-8B-Instruct --file ./ModeFile
```

```
● root@autodl-container-37b646b795-e9d5ca8a:~/autodl-tmp# ollama create llama-3-8B-Instruct --file ModeFile
transferring model data 100%
using existing layer sha256:9b518dcfafbeb8e29f34bea99de10641877d08a403c146a4d257d08b352f54e6
creating new layer sha256:64631f1262e4e87d47511bb7b405540321afd297f723f88bf72faae19992ddba
creating new layer sha256:4fc7dad80c9b29b5329e89004c0a7a722cd7e0fd229072a9cd613c8d8a8657ec
creating new layer sha256:30b13dcdd2f2db63a6d695f8e76cf629f4936880f7800bde331767b63212eb56
creating new layer sha256:b5c62d769201c2eded81d80db90b5c5d70cb35dc60ff583c747005e58df3924a
writing manifest
success
```

2.5 运行模型:

```
ollama run llama-3-8B-Instruct
```

```
○ root@autodl-container-37b646b795-e9d5ca8a:~/autodl-tmp# ollama run llama-3-8B-Instruct
>>> 你好
您好，我是 小聚，很高兴为您服务。有什么我可以帮您解决的问题或者需要我提供的帮助吗？<|im_end|>
```