

大模型微调

使用 LLaMA-Factory 微调 Qwen



课程内容

1.LoRA微调的基本原理

2.LLaMA-Factory介绍

3.使用 LLaMA-Factory 微调 Qwen

案例：自定义数据集完成Qwen微调训练

基本概念


- LoRA (Low-Rank Adaptation) 是一种用于大模型微调的技术，通过引入低秩矩阵来减少微调时的参数量。在预训练的模型中，LoRA通过添加两个小矩阵B和A来近似原始的大矩阵 ΔW ，从而减少需要更新的参数数量。具体来说，LoRA通过将全参微调的增量参数矩阵 ΔW 表示为两个参数量更小的矩阵B和A的低秩近似来实现：
- $[W_0 + \Delta W = W_0 + BA]$
- 其中，B和A的秩远小于原始矩阵的秩，从而大大减少了需要更新的参数数量。

思想

- 预训练模型中存在一个极小的内在维度，这个内在维度是发挥核心作用的地方。在继续训练的过程中，权重的更新依然也有如此特点，即也存在一个内在维度(内在秩)
- 权重更新: $W = W + \Delta W$
- 因此，可以通过矩阵分解的方式，将原本要更新的大的矩阵变为两个小的矩阵
- 权重更新: $W = W + \Delta W = W + BA$
- 具体做法，即在矩阵计算中增加一个旁系分支，旁系分支由两个低秩矩阵A和B组成


原理

- 训练时，输入分别与原始权重和两个低秩矩阵进行计算，共同得到最终结果，优化则仅优化A和B
- 训练完成后，可以将两个低秩矩阵与原始模型中的权重进行合并，合并后的模型与原始模型无异



课后作业

1. 掌握LoRA微调的基本概念
2. 掌握LLaMA-Factory配置与使用方法
3. 完成Qwen微调训练案例



End



Thanks